

SEGMENTAÇÃO DE IMAGENS



Definição

- Segmentação é o processo que divide uma imagem em regiões distintas, cada uma com pixels com atributos similares
 - ▣ Particiona os pixels de uma imagem em grupos, geralmente relacionados a objetos em uma imagem.
 - ▣ É uma tarefa básica no processo de análise de imagens
 - ▣ O sucesso da análise da imagem depende fortemente do resultado da etapa de segmentação

Definição

- O resultado de uma segmentação apenas é "correto" dado um determinado contexto
 - ▣ Subjetividade
 - ▣ Difícil implementação computacional.
 - ▣ Dificuldades na avaliação do desempenho.



Definição

- Os algoritmos de segmentação são geralmente baseados na busca pelas
 - ▣ Descontinuidades dos níveis de cinza
 - Exemplo: bordas
 - ▣ Similaridades dos níveis de cinza
 - Exemplo: regiões

Definição

□ Tipos de segmentação

▣ Limiarização

- Limiar local, limiar global, múltiplos limiares

▣ Bordas

- Detecção básica de bordas (Roberts, Prewitt, Sobel)
- Transformada de Hough
- Método de Marr-Hildreth,
- Método de Canny

▣ Regiões

- Crescimento de regiões
- Split-merge
- Watershed




Limiarização ou Thresholding

Limiarização ou Thresholding

- É uma técnica simples de segmentação
 - ▣ É um método global
 - ▣ Limiar único
 - Transforma a imagem em uma imagem binária (2 níveis de cinza)
 - ▣ Limiares múltiplos
 - Transforma a imagem em uma imagem com 2 ou mais níveis de cinza


Limiar único

- Segmenta a imagem em duas regiões:
 - ▣ Uma com valores menores que o limiar (rotulada com 0) e outra com valores maiores que o limiar (rotulada com 1)



Fazendo:


$$\begin{aligned} k_1 &= 0 \\ f_1(x,y) &= f_2(x,y) \\ k_3 \cdot f(x,y) &= W \end{aligned}$$



$$g(x,y) = \begin{cases} 0 & \Rightarrow 0 < f_1(x,y) \\ L-1 & \Rightarrow f_1(x,y) \leq f(x,y) \leq W \end{cases}$$

Limiar único

□ Exemplo




Limiar múltiplos

- Segmenta a imagem em duas regiões:
 - ▣ Dois ou mais limiares podem produzir mais do que duas regiões
 - ▣ Intervalos de níveis de cinza correspondentes a uma região são separados por limiares;


Limiar múltiplos

□ Exemplo



Escolhendo o Limiar

- Como escolher o limiar (ou os limiares) adequado para separar o objeto (ou os objetos) do background?
- ▣ Não é fácil achar um número mágico T ideal para o limiar!




Escolhendo o Limiar

- O resultado é muito sensível às variações de T
 - ▣ Bom para uma situação
 - ▣ Mau para todas as outras
- O sistema tem que ser robusto! Como escolher o limiar T ?
 - ▣ Histogramas
 - ▣ Outras técnicas

Escolhendo o Limiar

- Assume-se que o histograma de imagem é multimodal
 - ▣ Cada região corresponde a uma moda do histograma




- Imagem $f(x, y)$ composta de objetos brilhantes sobre fundo escuro
- Um ponto (x, y) é parte dos objetos se $f(x, y) > T$

Escolhendo o Limiar

□ Dificuldade

- ▣ Estabelecer múltiplos T que efetivamente isolem regiões de interesse




- Se $T_1 < f(x, y) \leq T_2 \rightarrow$ o ponto (x, y) pertence a uma classe de objetos.
- Se $f(x, y) > T_2 \rightarrow$ o ponto (x, y) pertence a outra classe.
- Se $f(x, y) \leq T_1 \rightarrow$ o ponto (x, y) pertence ao fundo.

Escolhendo o Limiar

- A limiarização deve ser capaz de encontrar o limiar que melhor separa os picos
 - ▣ Inspeção visual
 - O usuário escolhe o limiar baseando-se na inspeção visual do histograma
 - ▣ Tentativa e erro
 - Aplicado a processos interativos. O usuário testa diferentes níveis até produzir um resultado satisfatório para o observador
 - ▣ Obtenção automática do limiar
 - Análise do formato do histograma

Limiarização – técnicas para obter o limiar

□ Obtenção automática do limiar



Limiarização – técnicas para obter o limiar único

□ Limiar global adaptativo

- ▣ Obtido por refinamentos sucessivos da estimativa da posição de um pico
- ▣ Premissas básicas:
 - Cada pico coincide com a média de níveis de cinza de todos os pixels relacionados com este pico; (pico representa a região)
 - A probabilidade do pixel pertencer a uma região i é inversamente proporcional à diferença absoluta entre os valores do pixel e do pico que representa a região i ; (pixels são atribuídos às regiões representadas pelo pico mais próximo)
 - Cada nível de cinza da imagem é associado a um pico de acordo com o limiar definido como sendo a metade da distância entre dois picos. (limiar definido no meio de dois picos)

Limiarização – técnicas para obter o limiar único


- Limiarização global adaptativa
 - ▣ 1) Selecionar uma estimativa inicial para o limiar T
 - Deve ser um ponto entre os valores de intensidade mínimo e máximo (a intensidade média, por exemplo)
 - ▣ 2) Segmentar a imagem usando T . Isto produzirá dois grupos de pixels
 - $G1 \leq T$
 - $G2 > T$

Limiarização – técnicas para obter o limiar único

- Limiarização global adaptativa
 - ▣ 3) Computar a média das intensidades dos pixels em cada região
 - $\mu_1(G_1)$ e $\mu_2(G_2)$
 - ▣ 4) Computar o novo valor de T
 - $T = (\mu_1 + \mu_2) / 2$
 - ▣ 5) Repetir os passos de 2 a 4 até que a diferença entre dois valores sucessivos de T seja menor ou igual a ΔT


Limiarização – técnicas para obter o limiar único

- Limiarização global adaptativa - Exemplo
 - T inicial = média dos pixels da imagem
 - T resultante = 125,4 após 3 iterações
 - $\Delta T = 0$



Thresholding Global Ótimo

- Obtenção automática do limiar
 - ▣ A limiarização pode ser vista como um problema de decisão estatística cujo objetivo é minimizar o erro médio ocorrido na atribuição de pixels a uma ou mais classes;



Thresholding Global Ótimo

□ O método de Otsu (1979)

▣ Ideia

- maximizar a variância entre as classes (grupos)
- minimizar a variância interna das classes (grupos)

▣ Premissa

- As intensidades de pixels de uma mesma classe devem ser similares
 - As intensidades de pixels de classes diferentes devem ser diferentes
- ### ▣ O método se baseia inteiramente em cálculos realizados no histograma de uma imagem

Média e variância

- Qual a intensidade média da imagem?
- Qual a variância das intensidades da imagem?
 - Variância é uma medida do contraste de uma imagem

$$f(x, y) =$$

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26	27	28	29	30	31	32	
1	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	67	123	255	255	255	255	255	
2	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	120	52	90	255	255	255	255	255
3	255	255	255	255	255	255	255	94	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	58	71	83	255	255	255	255	255
4	255	255	255	255	255	255	255	51	120	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	61	84	79	76	255	255	255	255	255
5	255	255	255	255	255	255	255	55	57	161	255	255	255	255	255	255	255	255	255	255	255	255	255	98	60	87	98	80	71	255	255	255	255
6	255	255	255	255	255	255	255	63	109	74	100	255	255	255	255	255	255	255	255	130	104	60	85	102	88	83	81	65	255	255	255	255	255
7	255	255	255	255	255	255	255	88	139	141	137	96	73	133	255	255	177	114	79	88	110	100	79	73	87	80	67	255	255	255	255	255	
8	255	255	129	99	125	255	224	144	202	216	162	144	139	187	235	232	213	158	127	103	91	83	79	75	89	78	75	255	255	255	255	255	
9	255	62	13	35	19	57	134	255	223	236	132	70	147	218	169	222	74	96	137	92	89	85	81	77	92	76	83	255	255	255	255	255	
10	134	10	216	242	117	47	19	209	103	168	105	51	155	210	116	255	125	6	127	94	90	86	82	78	94	73	94	255	255	255	255	255	
11	104	37	251	255	122	86	41	58	151	10	11	64	140	197	43	45	30	15	133	94	90	86	82	78	98	68	118	255	255	255	255	255	
12	209	21	159	175	81	59	51	11	133	133	111	129	132	150	153	55	40	103	109	93	89	85	81	79	100	56	255	255	255	255	255	255	
13	255	27	69	66	61	49	37	13	76	113	110	110	111	126	137	137	135	110	95	91	87	84	80	87	89	60	255	255	255	255	255	255	
14	255	94	26	54	42	31	24	11	70	102	104	105	105	104	103	101	98	95	80	48	82	81	78	98	68	95	255	255	255	255	255	255	
15	255	255	88	15	26	23	15	6	91	97	99	100	100	99	98	96	93	57	10	6	32	79	89	91	54	127	255	255	255	255	255	255	
16	255	255	255	123	18	1	7	66	118	111	99	94	93	90	82	66	45	22	32	82	74	75	93	60	80	120	133	255	255	255	255	255	
17	255	255	255	255	255	209	116	57	63	91	114	113	101	93	88	86	83	82	78	78	115	93	65	99	121	128	209	255	255	255	255	255	
18	255	255	255	255	255	255	133	118	85	58	56	80	102	108	111	106	101	105	103	94	78	56	68	106	109	185	135	255	255	255	255	255	
19	255	255	255	255	255	255	209	130	118	107	84	61	52	51	57	65	71	59	52	52	55	75	94	88	114	185	233	186	118	120	255	255	
20	255	255	255	255	255	255	255	255	255	135	125	115	107	99	89	78	70	65	72	81	92	98	105	114	123	135	240	255	255	99	114	83	
21	255	255	255	255	255	255	255	255	255	255	209	131	125	120	117	115	114	114	116	120	124	132	255	255	255	255	255	255	110	92	79	56	240
22	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	108	72	43	98
23	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	255	144	75	47	



Média e variância


- É possível obter essas informações a partir do histograma da imagem?

- Média

$$\mu = \frac{\sum_{x=0}^N \sum_{y=0}^M f(x, y)}{MN}$$

- Variância

$$\sigma^2 = \frac{1}{MN} \sum_{x=0}^N \sum_{y=0}^M (f(x, y) - \mu)^2$$



Média e variância

□ Qual a média das intensidades a partir deste histograma?


□ Soma dos valores dos pixels:

■ $5 \times 0 + 9 \times 1 + 6 \times 2 + \dots + 7 \times 11 = 188$

□ Total de Pixels:

■ $5 + 9 + 6 + 4 + \dots + 11 = 49$

□ Média = 3.83



Definições

- L distintos níveis de cinza
 - ▣ $\{0, 1, 2, 3..., L-1\}$
 - ▣ Exemplo anterior: $L = 8$
- n_i - número de pixels com intensidade i
 - ▣ Exemplo anterior: $n_0 = 5, n_1 = 9, ...$
- Tamanho da imagem $M \times N$
 - ▣ $MN = n_0 + n_1 + ... + n_{L-1}$
 - ▣ Exemplo anterior: $5 + 9 + ... + 11 = 49$

Média a partir do histograma

- Qual a média das intensidades a partir deste histograma?

$$\sum_{i=0}^{i=L-1} in_i$$

- Soma dos valores dos pixels:

$$5 \times 0 + 9 \times 1 + 6 \times 2 + \dots + 7 \times 11 = 188$$


$$\sum_{i=0}^{i=L-1} n_i$$

- Total de Pixels:

$$5 + 9 + 6 + 4 + \dots + 11 = 49$$

- Média = 3.83


$$\frac{\sum_{i=0}^{i=L-1} in_i}{\sum_{i=0}^{i=L-1} n_i}$$



Média a partir do histograma

- Qual a média das intensidades a partir do histograma NORMALIZADO?
- Temos agora uma distribuição de probabilidades

0	1	2	3	4	5	6	7
0.10	0.18	0.12	0.08	0.00	0.12	0.16	0.22



Média a partir do histograma


- Qual a média das intensidades a partir do histograma NORMALIZADO?

$$p_i = n_i/MN \rightarrow n_i = p_i * MN$$

$$\sum_{i=0}^{i=L-1} i n_i = \sum_{i=0}^{i=L-1} i p_i MN$$

$$\sum_{i=0}^{i=L-1} n_i = \sum_{i=0}^{i=L-1} p_i MN$$

MN é uma constante, que sai do somatório e, neste caso é eliminada



Média a partir do histograma

- Lembrando que a soma de todas as probabilidades é igual a 1

$$\sum_{i=0}^{L-1} p_i = 1$$

Média

$$\frac{\sum_{i=0}^{L-1} i n_i}{\sum_{i=0}^{L-1} n_i}$$



Média

$$\frac{\sum_{i=0}^{L-1} i p_i MN}{\sum_{i=0}^{L-1} p_i MN}$$



Média

$$\frac{\sum_{i=0}^{L-1} i p_i}{\sum_{i=0}^{L-1} p_i}$$



Média

$$\sum_{i=0}^{L-1} i p_i$$




$$\mu = \sum_{i=0}^{L-1} i p_i$$

Variância a partir do histograma

- Como calcular a variância?

$$\sigma^2 = \frac{1}{MN} \sum_{x=0}^N \sum_{y=0}^M (f(x, y) - \mu)^2$$



Variância a partir do histograma

□ Como calcular a variância?

▣ Soma dos pixels menos a média

■ $5 \cdot (0 - \mu)^2 + 9 \cdot (1 - \mu)^2 + \dots + 11 \cdot (7 - \mu)^2$

$$\sum_{i=0}^{i=L-1} n_i (i - \mu)^2$$

▣ Total de pixels (MN)

■ $5 + 9 + 6 + 4 + \dots + 11 = 49$

$$\sum_{i=0}^{i=L-1} n_i$$

$$\sigma^2 = \frac{1}{MN} \sum_{x=0}^N \sum_{y=0}^M (f(x, y) - \mu)^2$$


Variância

$$\frac{\sum_{i=0}^{i=L-1} n_i (i - \mu)^2}{\sum_{i=0}^{i=L-1} n_i}$$

Variância a partir do histograma

- E se for um histograma NORMALIZADO?
 - ▣ Temos agora uma distribuição de probabilidades

0	1	2	3	4	5	6	7
0.10	0.18	0.12	0.08	0.00	0.12	0.16	0.22



Variância a partir do histograma


- Qual a variância de um histograma NORMALIZADO?

$$p_i = n_i / MN \rightarrow n_i = p_i * MN$$

$$\sum_{i=0}^{i=L-1} i n_i = \sum_{i=0}^{i=L-1} i p_i MN$$

$$\sum_{i=0}^{i=L-1} n_i = \sum_{i=0}^{i=L-1} p_i MN$$

MN é uma constante, que sai do somatório e, neste caso é eliminada



Limiar e Classes

- Suponha que selecionemos um limiar k
 - ▣ $0 < k < L-1$
 - ▣ Separar em duas classes C_1 e C_2
 - C_1 : pixels entre $[0, k]$
 - C_2 : pixels entre $[k+1, L-1]$

Probabilidade

□ Limiar k

- $0 < k < L-1$

- Qual a probabilidade P_1 de um pixel pertencer a classe C_1

- C_1 : pixels em $[0, k]$

$$P_1 = \sum_{i=0}^k p_i$$

- Qual a probabilidade P_2 de um pixel pertencer a classe C_2

- C_2 : pixels em $[k+1, L-1]$

$$P_2 = \sum_{i=k+1}^{L-1} p_i = 1 - P_1$$

Média da região

□ Limiar k

- $0 < k < L-1$

- Qual a média da intensidade m_1 dos pixels que pertencem a classe C_1

 - C_1 : pixels em $[0, k]$

- Soma dos valores dos pixels:


- $5 \times 0 + 9 \times 1 + 6 \times 2 + 4 \times 3 = 33$

- Total de Pixels:

- $5 + 9 + 6 + 4 = 24$

- Média

- 1.375



Média da região

□ Qual a média da região C_1 ?


▣ C_1 : pixels em $[0,k]$

$$p_i = n_i/MN \rightarrow n_i = p_i * MN$$

$$\sum_{i=0}^{i=k} in_i = \sum_{i=0}^{i=k} ip_i MN$$

$$\sum_{i=0}^{i=k} n_i = \sum_{i=0}^{i=k} p_i MN$$

MN é uma constante, que sai do somatório e, neste caso é eliminada



Média da região

□ Lembrando que

$$P_1 = \sum_{i=0}^k p_i$$

Média

$$\frac{\sum_{i=0}^k i n_i}{\sum_{i=0}^k n_i}$$



Média

$$\frac{\sum_{i=0}^k i p_i MN}{\sum_{i=0}^k p_i MN}$$



Média

$$\frac{\sum_{i=0}^k i p_i}{\sum_{i=0}^k p_i}$$



Média

$$\frac{1}{P_1} \sum_{i=0}^k i p_i$$



$$m_1 = \frac{1}{P_1} \sum_{i=0}^k i p_i$$

Média da região

□ Limiar k

□ $0 < k < L-1$

- Qual a média da intensidade m_1 dos pixels que pertencem a classe C_1

- C_1 : pixels em $[0, k]$


$$m_1 = \frac{1}{P_1} \sum_{i=0}^k i p_i$$

- Qual a média da intensidade m_2 dos pixels que pertencem a classe C_2

- C_2 : pixels em $[k+1, L-1]$

$$m_2 = \frac{1}{P_2} \sum_{i=k+1}^{L-1} i p_i$$

Limiar e média da região



Otsu

- A fim de avaliar a "qualidade" do limiar no nível k , usamos a métrica normalizada adimensional

$$\eta(k) = \frac{\sigma_B^2(k)}{\sigma_G^2}$$

- Variância Global: σ_G^2 (constante)
- Variância entre classes: $\sigma_B^2(k)$ (depende de k)

Variância “global” e “entre classes”

□ Variância global σ_G^2

Fórmula geral $\sigma^2 = \frac{1}{MN} \sum_{x=0}^N \sum_{y=0}^M (f(x,y) - \mu)^2$ $\Rightarrow$ $\sigma^2 = \sum_{i=0}^{L-1} p_i (i - \mu)^2$ $\Rightarrow$ $\sigma_G^2 = \sum_{i=0}^{L-1} p_i (i - m_g)^2$

□ Variância entre classes σ_B^2

$$\sigma_B^2 = P_1(m_1 - m_g)^2 + P_2(m_2 - m_g)^2$$

$$\sigma_B^2 = P_1 P_2 (m_1 - m_2)^2 = \frac{(m_g P_1 - m)^2}{P_1(1 - P_1)}$$

Média acumulada $m(k) = \sum_{i=0}^k i p_i$

Quanto maior a distância entre m_1 e m_2 , maior será o valor da variância entre classes σ_B^2

Otsu - Thresholding Global Ótimo

- Queremos separação máxima entre classes, isso implica em maximizar

$$\eta(k) = \frac{\sigma_B^2(k)}{\sigma_G^2}$$

- Como σ_G^2 é constante. Podemos maximizar apenas $\sigma_B^2(k)$
 - ▣ Para achar k , basta avaliar a expressão acima para todo inteiro k , e selecionar o valor de k que maximiza a expressão
 - ▣ O thresholding é feito usando o valor k

Algoritmo de Otsu

□ Passos

- Calcular o histograma normalizado da imagem de entrada (p_i), $i=1,2,3,\dots,L-1$
- Calcular $P_1(k)$ e $P_2(k)$, $k = 0,1,2 \dots L-1$
- Calcular μ_1 e μ_2 , $k = 0,1,2,\dots,L-1$
- Calcular μ_G
- Calcular a variância entre classes $\sigma_B^2(k)$, $k = 0,1,2,\dots,L-1$
- Obter o limiar Otsu k (se o k não for único, calcular a média dos candidatos)
- Calcular a variância geral (σ_G^2)
- Avaliar a separabilidade obtida com a limiarização

Exemplo

a b
c d


FIGURE 10.39

(a) Original image.

(b) Histogram (high peaks were clipped to highlight details in the lower values).

(c) Segmentation result using the basic global algorithm from Section 10.3.2.




(d) Result obtained using Otsu's method. (Original image courtesy of Professor Daniel A. Hammer, the University of Pennsylvania.)



T obtido pelo método adaptativo básico=169

T obtido pelo Otsu =181 ; $\eta =0.467$


Exemplo



Slide adaptado do grupo IMAGO - UFPR

Melhorando o Thresholding Global

- Ruído pode tornar a limiarização um problema insolúvel
- ▣ Suavizar a imagem antes de executar o thresholding.



Multiplos Thresholds

- O método de Otsu pode ser estendido para múltiplos thresholds
 - ▣ O resultado começa a perder o significado à medida que aumenta o número de classes




FIGURE 10.45 (a) Image of iceberg. (b) Histogram. (c) Image segmented into three regions using dual Otsu thresholds. (Original image courtesy of NOAA.)

Múltiplos Thresholds

- Na prática, a limiarização global múltipla é usada quando se acredita que problema possa ser resolvido com 2 limiares
- ▣ Em geral, problemas que requerem mais de 2 limiares são resolvidos usando mais informações além da intensidade do pixel ou outros métodos de segmentação mais apropriados

Thresholding Variável

□ Problema

- ▣ Ruído ou iluminação não uniforme podem comprometer o desempenho dos algoritmos de limiarização
- ▣ A suavização pode melhorar os resultados, mas frequentemente não é efetivo

□ Solução → thresholding variável

- ▣ Particionamento da imagem
- ▣ Uso de propriedades locais da imagem

Thresholding Variável

- Particionamento da imagem
 - ▣ É utilizada para compensar problemas na iluminação ou na reflectância
 - ▣ Subdivide a imagem em retângulos que não se sobrepõem
 - Otsu é aplicado a cada retângulo
 - ▣ Os retângulos devem ser pequenos o suficiente para que a iluminação em cada um seja aproximadamente uniforme

Thresholding Variável

□ Particionamento da imagem




FIGURE 10.46 (a) Noisy, shaded image and (b) its histogram. (c) Segmentation of (a) using the iterative global algorithm from Section 10.3.2. (d) Result obtained using Otsu's method. (e) Image subdivided into six subimages. (f) Result of applying Otsu's method to each subimage individually.

Thresholding Variável

- Particionamento da imagem
 - ▣ Subdivisão de imagem funciona bem nos casos em que os objetos de interesse e o fundo ocupam regiões de tamanhos aproximadamente iguais
 - ▣ Quando isto não acontece, o método falha porque uma subdivisão pode conter apenas objeto ou apenas fundo

Thresholding Variável

- Uso de propriedades locais
 - ▣ Para cada pixel (x, y) e uma vizinhança S_{xy} , calcula a media m_{xy} e o desvio padrão σ_{xy}
 - ▣ Threshold
 - $T_{xy} = a.\sigma_{xy} + b.m_{xy}$
 - ou
 - $T_{xy} = a.\sigma_{xy} + b.G_{xy}$
 - ▣ A imagem segmentada é obtida como

$$g(x, y) = \begin{cases} 1 & \text{se } f(x, y) > T_{xy} \\ 0 & \text{se } f(x, y) \leq T_{xy} \end{cases}$$

Thresholding Variável

- Uso de propriedades locais
 - ▣ Podemos usar predicados baseados nos parâmetros calculados na vizinhança de (x,y)

$$g(x, y) = \begin{cases} 1 & \text{se } Q(\text{parametros locais}) \text{ é true} \\ 0 & \text{se } Q(\text{parametros locais}) \text{ é false} \end{cases}$$

Por exemplo, considere o predicado $Q(\sigma_{xy}, m_{xy})$

$$Q(\sigma_{xy}, m_{xy}) = \begin{cases} \text{true} & \text{se } f(x, y) > a.\sigma_{xy} \text{ AND } f(x, y) > b.m_{xy} \\ \text{false} & \text{caso contrário} \end{cases}$$

Thresholding Variável

- Uso de propriedades locais




Imagem de levedura
(possui 3 regioes)



Imagem segmentada usando
Otsu com 2 limiares.

Thresholding Variável

□ Uso de propriedades locais



Calcula o desvio padrão para cada pixel (x,y) numa vizinhança 3×3 .

Imagem que mostra o resultado do desvio padrão local. As fronteiras das células são visíveis.



Resultado da segmentação local usando média geral em vez de média local
 $a = 30$ e $b = 1,5$.

Intensidade média de movimento (moving average)

- Técnica útil em processamento de texto
 - ▣ A media é obtida ao longo do scan line da imagem
 - ▣ Seja z_{k+1} a intensidade de um ponto encontrado na sequência do scanning no passo $k+1$. A intensidade média (moving average) neste ponto é obtida por

$$m(k+1) = \frac{1}{n} \sum_{i=k+2-n}^{k+1} z_i$$

$$m(1) = z_1 / n$$

Intensidade média de movimento (moving average)

□ Observações

▣ O valor $m(1)$ não é correto

- É como se a imagem tivesse $n-1$ zeros para preencher os pixels de borda

▣ O algoritmo é inicializado apenas 1 vez

- Não reinicializar a cada linha!

▣ Transformação pontual

- $T_{xy} = b.m_{xy}$, $b > 0$, em que m_{xy} é a moving average no ponto (x,y)

Intensidade média de movimento (moving average)

- Observações

- ▣ Valor mágico para n

- 5 vezes a largura da letra


- ▣ O método funciona bem em aplicações em que os objetos de interesse são pequeno (ou finos) com respeito ao tamanho da imagem

Intensidade média de movimento (moving average)

□ Exemplo

■ $n = 20$

■ $b = 0.5$



Intensidade média de movimento (moving average)

□ Exemplo

■ $n = 20$

■ $b = 0.5$




FIGURE 10.50 (a) Text image corrupted by sinusoidal shading. (b) Result of global thresholding using Otsu's method. (c) Result of local thresholding using moving averages.



Detecção de Descontinuidades

Detecção de Descontinuidades

- Segmentação de pontos isolados
 - ▣ Ponto isolado = Ponto que se destaca dos demais
 - ▣ Feita através do uso de um filtro passa altas e um limiar de aceitação

-1	-1	-1
-1	8	-1
-1	-1	-1

$$|R| > T$$

Detecção de Descontinuidades

- Segmentação de linhas
 - ▣ Feita através do uso de um filtro passa altas direcionais
 - ▣ Uso de um limiar de aceitação

-1	-1	-1
2	2	2
-1	-1	-1

horizontal

-1	-1	2
-1	2	-1
2	-1	-1

+45 graus

-1	2	-1
-1	2	-1
-1	2	-1


vertical

2	-1	-1
-1	2	-1
-1	-1	2

-45 graus

Detecção de Descontinuidades

- Segmentação de bordas
 - ▣ Borda: limite entre duas regiões com propriedades relativamente distintas de nível de cinza
 - Roberts, Prewitt, Sobel, Laplaciano
 - ▣ Vetor de Gradiente
 - Verifica se a magnitude é maior que um certo valor





Magnitude



$M > 0.2$

Detecção de Descontinuidades

- Transformada de Hough
 - Permite encontrar formas em imagens
 - Retas, círculos e elipses (seções cônicas)




Detecção de Descontinuidades

□ Transformada de Hough


□ Espaço dual

- pontos são transformados em retas, e vice-versa
- todos pontos colineares em uma imagem, definem o pontos de interseção (A,B) no espaço dual
- Encontra a reta (A,B) rastreando o acumulo das evidências



Detecção de Descontinuidades

□ Transformada de Hough



a b c


FIGURE 10.32 (a) (ρ, θ) parameterization of line in the xy -plane. (b) Sinusoidal curves in the $\rho\theta$ -plane; the point of intersection (ρ', θ') corresponds to the line passing through points (x_i, y_i) and (x_j, y_j) in the xy -plane. (c) Division of the $\rho\theta$ -plane into accumulator cells.

Detecção de Descontinuidades

□ Transformada de Hough


□ Votação

- Cada ponto (x_i, y_i) forma uma reta U_i no espaço dual
- Cada reta U_i vota em todos pontos pelos quais ela passa
- pontos que obtém muitos votos no espaço dual, são os candidatos para serem retas na imagem



Detecção de Descontinuidades

□ Transformada de Hough





Detecção de Regiões

Definição

- Baseia-se em conjuntos.
 - ▣ A imagem R é um conjunto de regiões R_i
 - ▣ Todos os pontos pertencem a uma das regiões
 - ▣ Um ponto apenas pode pertencer a uma única região
 - ▣ Eficaz em imagens ruídas




Crescimento de Regiões

- Consiste na união/divisão de um conjunto inicial de regiões
 - ▣ Baseado em algum critério de homogeneidade
 - Cor
 - Textura
 - Etc
 - ▣ Tipicamente iterativo
 - Region merging
 - Region splitting
 - Split-merge

Crescimento de Regiões


□ Region merging

- ▣ Divisão inicial da imagem em regiões
- ▣ Definição do critério de união de 2 regiões adjacentes.
- ▣ Unir regiões
- ▣ Repetir passo anterior até não haver mais uniões



(a) Start of Growing a Region

- Seed Pixel
- ↑ Direction of Growth




(b) Growing Process After a Few Iterations

- Grown Pixels
- Pixels Being Considered

Crescimento de Regiões


□ Region splitting

- Inicialmente usa a imagem completa
- Definição do critério de divisão
- Divisão iterativa em sub-regiões
- Parada quando falhar o critério de divisão



Crescimento de Regiões

- Split-merge
 - ▣ Combinação dos dois algoritmos
 - ▣ Permite lidar com formas mais variadas
 - ▣ Basta aplicar consecutivamente os algoritmos anteriores



Transformada Watershed

- Inspiração geográfica
 - ▣ Lançar água sobre um terreno montanhoso
 - ▣ Cada lago corresponde a uma região
- Características
 - ▣ Computacionalmente complexo
 - ▣ Grande flexibilidade na segmentação
 - ▣ Resultados mais estáveis
 - ▣ Risco de super-segmentação

Transformada Watershed

□ Funcionamento

- ▣ Suponha que em cada mínimo local tenha um ponto que seja uma fonte de água
- ▣ A água sobe inundando as regiões, de baixo para cima
- ▣ A água sobe em uma taxa uniforme
- ▣ As bordas da imagem podem ser consideradas como sendo uma barragem mais alta que a maior montanha

Transformada Watershed

□ Funcionamento

- ▣ Quando a água está prestes a se fundir nas diversas watersheds, uma barragem é construída para impedir a fusão
- ▣ A inundação chegará a um ponto em que somente apenas os topos das barragens serão visíveis acima da linha d'água
- ▣ Essas linhas são as Linhas de divisão ou linhas de Watershed
- ▣ Portanto, são as fronteiras conectadas que são extraídas em um algoritmo de segmentação Watershed.

Transformada Watershed

□ Exemplo

